UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3084 – Data Science

Sección 20

Ing. Mario Barrientos



Proyecto 2

Predicción de preferencias humanas en Chatbot Arena

Mia Alejandra Fuentes Mérida, 23775

Roberto Jose Barreda Siekavizza, 23354

Javier Eduardo España Pacheco, 23361

Angel Esteban Esquit Hernández, 23221

7 de septiembre de 2026

Situación problemática

Los modelos de lenguaje grande (LLMs) se han incorporado rápidamente a productos de asistencia virtual, generación de contenido, búsqueda, educación, programación y soporte al cliente. Para una organización que quiere integrar este tipo de tecnología no basta con conocer el tamaño del modelo o su rendimiento en un benchmark técnico: la decisión final depende de si las respuestas realmente resultan útiles, claras y preferibles para las personas que las utilizan.

El reto analizado utiliza datos de Chatbot Arena, una plataforma en la que dos modelos responden al mismo prompt y el usuario selecciona cuál respuesta prefiere o indica un empate. La comparación se hace de forma ciega, de modo que el evaluador no conoce la identidad de los modelos al votar. Esta metodología permite observar preferencias humanas directamente y es especialmente relevante para el problema planteado por la competencia LMSYS - Chatbot Arena Human Preference Predictions (Kaggle, 2024).

Desde el punto de vista de negocio, identificar los factores asociados con la preferencia humana puede apoyar la selección de un modelo para producción, el diseño de sistemas de enrutamiento entre modelos y la evaluación del balance entre calidad y costo. También permite detectar factores de confusión. Por ejemplo, si los usuarios tienden a favorecer respuestas más extensas, un ranking bruto podría premiar verbosidad en lugar de utilidad.

Contexto técnico del problema

La evaluación de asistentes conversacionales es difícil porque una misma pregunta puede admitir varias respuestas correctas y la calidad no siempre se resume con coincidencia de palabras. Chatbot Arena aborda esa limitación mediante comparaciones por pares basadas en preferencia humana. Trabajos del propio proyecto LMSYS han documentado que este tipo de evaluación permite estudiar aspectos como sesgo de posición y sesgo por verbosidad, dos temas que también se revisan en este análisis (Zheng et al., 2023; Chiang et al., 2024).

En un problema de procesamiento del lenguaje natural, los patrones pueden representarse con características simples del texto —longitud, número de palabras, número de turnos— y posteriormente con representaciones más ricas del contenido, como embeddings o modelos basados en Transformers. Este proyecto se concentra en la fase exploratoria: primero se determina qué señales ya aparecen en las variables disponibles y qué aspectos deberían controlarse en una etapa posterior de modelado.

Problema científico

¿Es posible identificar, a partir de características observables del prompt, de las respuestas y de los modelos enfrentados, patrones que permitan explicar la preferencia humana en una evaluación ciega por pares entre modelos de lenguaje grande?

A partir de esta pregunta se analizaron cinco cuestiones concretas:

- si la longitud de la respuesta se relaciona con la preferencia del usuario;
- si existen modelos con tasas de victoria consistentemente superiores;
- si la posición A o B introduce una ventaja sistemática;
- cómo se comportan los empates y qué enfrentamientos los producen con mayor frecuencia;
- qué variables cuantitativas muestran relaciones suficientemente claras como para ser útiles en el modelado posterior.

Objetivo general

Realizar un análisis exploratorio del dataset LMSYS Chatbot Arena para identificar patrones, variables relevantes y factores de confusión asociados con la preferencia humana entre respuestas de modelos de lenguaje, de forma que los resultados sirvan como base para una etapa posterior de modelado predictivo.

Objetivos específicos

1. Describir la estructura del dataset, sus variables, dimensiones y calidad, incluyendo valores nulos, duplicados y consistencia de los turnos.
2. Preparar un dataset limpio y analizable, transformando las columnas de conversación serializadas en JSON y construyendo variables de longitud y número de turnos.
3. Caracterizar las variables cuantitativas mediante estadística descriptiva, distribuciones, diagramas de caja, análisis de valores atípicos y gráficos de dispersión.
4. Estudiar las variables categóricas y sus proporciones, incluyendo participación de modelos, tasa de victoria, tasa de empate y comportamiento según la posición A/B.
5. Analizar relaciones entre características de las respuestas y el resultado, con énfasis en longitud, correlaciones, empates y posible sesgo de posición.
6. Resumir los hallazgos y proponer los siguientes pasos para construir un modelo que prediga la preferencia humana sin confundir calidad con verbosidad, posición o composición de rivales.

Descripción de los datos

Origen y unidad de análisis

Los datos provienen de la competencia LMSYS - Chatbot Arena Human Preference Predictions. El archivo principal train.csv contiene 57,477 batallas y 9 columnas. Cada fila representa un enfrentamiento entre dos modelos: un usuario proporciona uno o más turnos de conversación, recibe una respuesta de model_a y otra de model_b, y registra una preferencia entre tres opciones: victoria de A, victoria de B o empate.

Variable	Tipo	Descripción
id	Identificador	Identificador único de la batalla.
model_a	Categórica	Modelo colocado en la posición A.
model_b	Categórica	Modelo colocado en la posición B.
prompt	Texto / JSON	Lista serializada con los turnos del usuario.
response_a	Texto / JSON	Lista serializada con las respuestas del modelo A.
response_b	Texto / JSON	Lista serializada con las respuestas del modelo B.
winner_model_a	Binaria	Vale 1 cuando el usuario prefiere a model_a.
winner_model_b	Binaria	Vale 1 cuando el usuario prefiere a model_b.
winner_tie	Binaria	Vale 1 cuando el usuario declara empate.

Las tres variables de resultado son mutuamente excluyentes: exactamente una toma el valor 1 en cada batalla. También se verificó que existen 64 modelos distintos tanto en la posición A como en la B.

Calidad de los datos y preprocesamiento

La limpieza se diseñó para conservar información válida y eliminar únicamente observaciones que pudieran sobreponderar un enfrentamiento o impedir el análisis del texto. Se revisaron duplicados por identificador y por contenido, parseo de JSON, consistencia del número de turnos, ausencia de datos y respuestas vacías.

Control	Resultado	Decisión
Duplicados por id	0 filas	No se requirió eliminación por este criterio.
Duplicados de contenido	71 filas	Se conservó la primera aparición; el dataset quedó en 57,406 filas.
JSON no parseable	0 filas	No se detectaron casos luego de usar parseo tolerante.
Inconsistencia de turnos	0 filas	Prompt y ambas respuestas tuvieron el mismo número de turnos.
Nulos a nivel de celda	0	No se detectaron valores nulos en las columnas del dataframe.

Control	Resultado	Decisión
Turnos sin respuesta en A	120 turnos / 111 filas	Se conservaron; el turno vacío aporta longitud 0.
Turnos sin respuesta en B	126 turnos / 120 filas	Se conservaron por la misma razón.

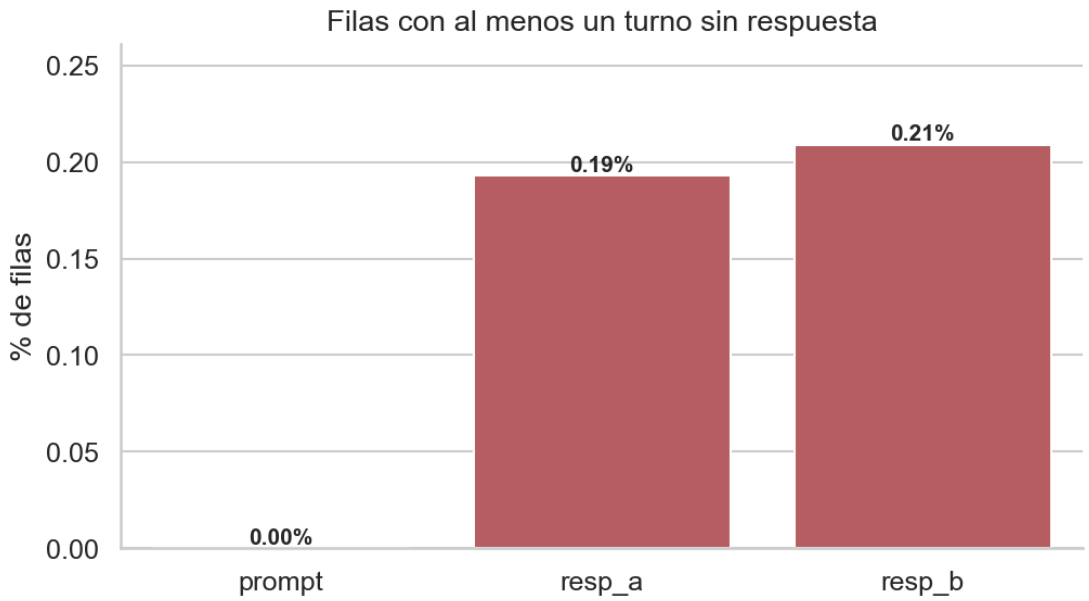


Figura 1. Porcentaje de filas con al menos un turno sin respuesta.

Los turnos vacíos no se eliminaron porque forman parte de lo que el usuario observó antes de emitir su voto. Sustituirlos o eliminar toda la batalla alteraría la experiencia evaluada. En el texto unificado, un turno faltante se representa como cadena vacía, lo que deja que la longitud final refleje lo que el modelo realmente produjo.

Variables derivadas

Después de deserializar las listas JSON se generaron columnas de texto plano para el prompt y ambas respuestas. También se construyó una variable categórica winner (0 = gana A, 1 = gana B, 2 = empate) y siete variables cuantitativas: prompt_len, resp_a_len, resp_b_len, prompt_words, resp_a_words, resp_b_words y n_turns. El dataset procesado quedó con 57,406 filas y 17 columnas, conservando 99.88% de las observaciones originales.

Las columnas JSON originales se excluyeron del archivo limpio porque su contenido ya estaba representado en las versiones de texto plano. Esta decisión reduce duplicación de información y mantiene el archivo procesado en una forma más apropiada para el análisis.

Análisis exploratorio

1. ***Distribución de la variable objetivo***

Resultado	Frecuencia	Proporción
model_a gana	20,055	34.94%
model_b gana	19,643	34.22%
empate	17,708	30.85%

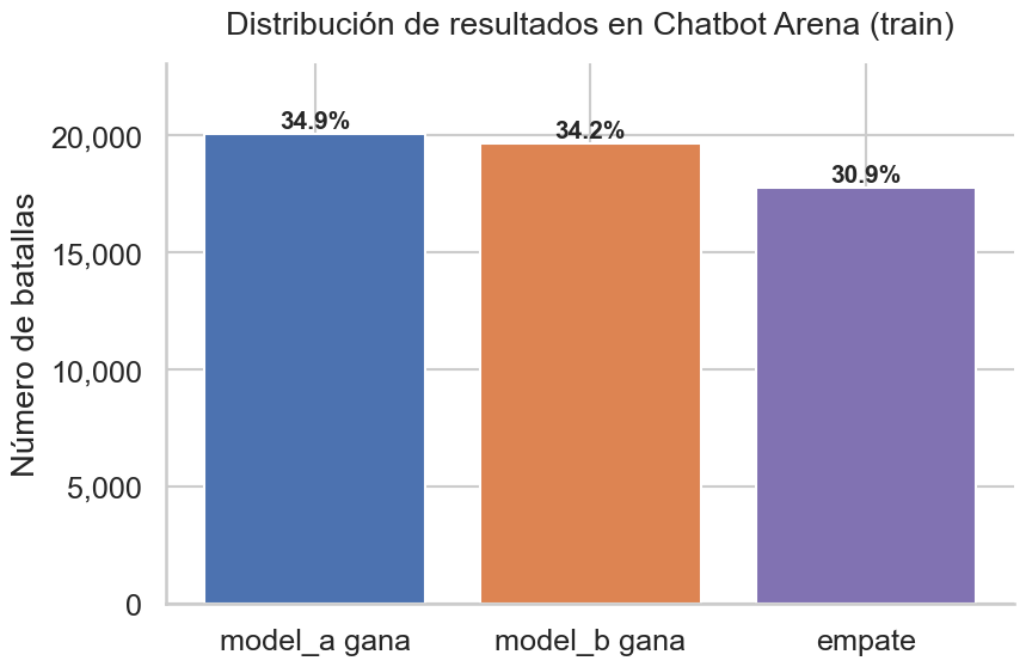


Figura 2. Distribución de resultados en el dataset limpio.

Las tres clases están relativamente equilibradas. Las victorias de A y B tienen una diferencia bruta de solo 0.72 puntos porcentuales sobre el total, mientras el empate representa casi un tercio de las batallas. Esto evita un desbalance extremo de clases y confirma que el empate debe tratarse como una categoría real, no como ruido o información descartable.

2. ***Estadística descriptiva de las variables cuantitativas***

Variable	Media	Mediana	P95	P99	Máximo
prompt_len	352.4	91	1,419	4,720.3	32,832
resp_a_len	1,332.0	1,038	3,587	6,785.8	53,299
resp_b_len	1,338.8	1,045	3,577.8	6,736.9	52,402
prompt_words	56.3	16	229	666	4,809
resp_a_words	212.6	170	559	1,034	9,184
resp_b_words	213.4	171	559	1,048.9	8,173
n_turns	1.24	1	2	5	36

Las medias son mayores que las medianas y las medidas de asimetría son positivas, lo que evidencia colas largas hacia la derecha. El prompt típico es corto: su mediana es de 91 caracteres. Las respuestas tienen medianas cercanas a 1,040 caracteres. Una respuesta típica resulta aproximadamente 11.4 veces más extensa que el prompt que la origina.

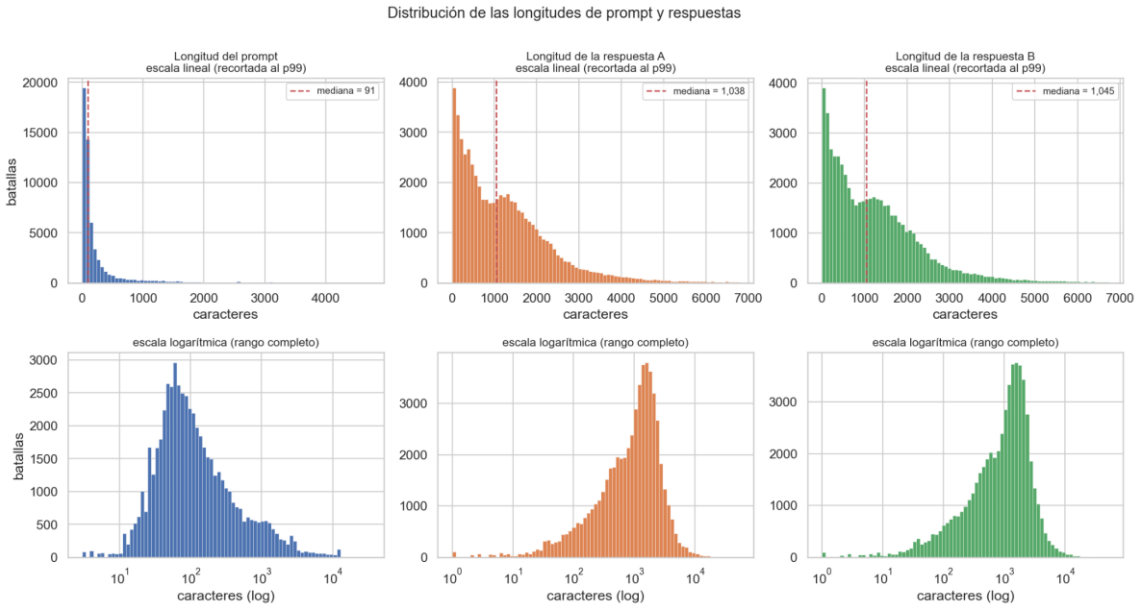


Figura 3. Distribución de las longitudes de prompt y respuestas en escala lineal y logarítmica.

La forma de las distribuciones es compatible con una distribución log-normal: en escala lineal los datos se concentran cerca del origen, mientras en escala logarítmica aparece una forma mucho más regular. Para una fase de modelado conviene trabajar con transformaciones como log(1 + longitud) o mecanismos robustos que eviten que unas pocas respuestas extremadamente largas dominen el ajuste.

La correlación entre longitud en caracteres y longitud en palabras es casi perfecta: 0.9683 para el prompt, 0.9883 para la respuesta A y 0.9855 para la respuesta B. Por esa redundancia, el resto del EDA utiliza principalmente caracteres como medida de extensión.

3. Número de turnos

El 86.87% de las batallas tiene un solo turno y 13.13% contiene más de uno. Las conversaciones largas son rápidamente menos frecuentes: 4,672 batallas tienen dos turnos, 1,485 tienen tres y solo casos aislados llegan a decenas de turnos. La tasa de empate de un turno es 31.26%; en varios niveles de 2 a 9 turnos se ubica aproximadamente entre 22.7% y 28.7%, aunque las muestras se vuelven pequeñas conforme aumenta la duración.

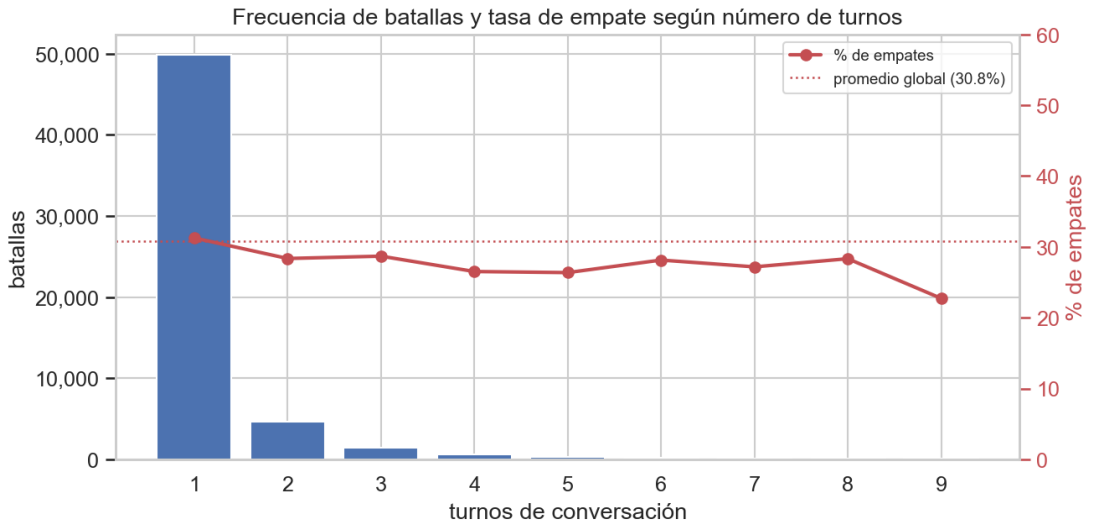


Figura 4. Frecuencia de batallas y tasa de empate según número de turnos.

No se encontró una relación fuerte entre número de turnos y quién gana. En los niveles extremos los porcentajes son inestables porque se calculan sobre muy pocas observaciones, por lo que no se interpretaron como patrones generales.

4. Longitud de respuesta y preferencia humana

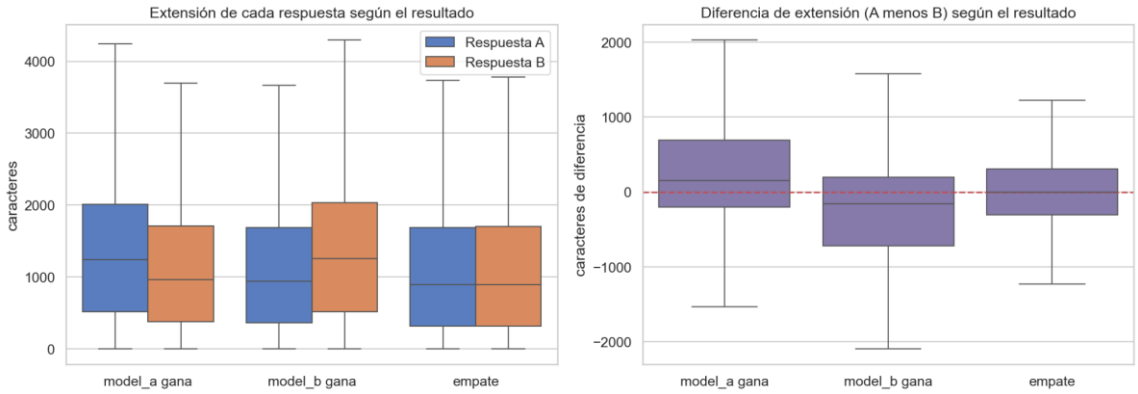


Figura 5. Extensión de las respuestas y diferencia A - B según el resultado.

Las medianas muestran una señal consistente. Cuando gana A, su respuesta tiene una mediana de 1,241 caracteres frente a 962 para B. Cuando gana B ocurre el patrón inverso: 1,259 caracteres para B frente a 943 para A. En los empates, las medianas de ambas respuestas son muy parecidas, 894.5 y 893 caracteres.

Entre las 39,698 batallas con un ganador definido, la respuesta ganadora tiene una mediana de 1,251 caracteres y la perdedora de 952. Si se consideran únicamente las 39,597 batallas decisivas en las que las longitudes son distintas, la respuesta más larga gana 61.63% de las

veces. Esto equivale a una ventaja de 11.63 puntos porcentuales frente a una referencia de 50%.

El efecto es relevante, pero no determinante: cerca de cuatro de cada diez veces la respuesta más larga no resulta ganadora. Además, la diferencia absoluta de longitud tiene una mediana de 307 caracteres en los empates y 463 en las batallas decisivas, una diferencia de 50.8%. Estos resultados justifican incluir la diferencia de longitud como variable, pero también muestran que hace falta representar contenido y calidad.

5. Valores atípicos

Aplicar la regla clásica de 1.5 veces el rango intercuartílico marcaría como atípico al 13.41% de los prompts y aproximadamente 3.8% de cada conjunto de respuestas. Al revisar los extremos se encontraron conversaciones reales y bien formadas, incluyendo código, enumeraciones extensas y diálogos de muchos turnos. Los máximos observados fueron 32,832 caracteres para prompts, 53,299 para respuestas A y 52,402 para respuestas B.

Por esta razón los valores extremos se conservaron. Eliminarlos habría descartado parte válida de la variabilidad natural del texto. Para modelado se recomienda transformar la escala o aplicar recortes controlados para fines numéricos, no eliminar las observaciones del conjunto original.

También se identificaron 45 batallas con al menos una respuesta completamente vacía, equivalentes a 0.078% del dataset. Su distribución de resultados no justificó borrarlas: son situaciones observadas por el evaluador y forman parte del fenómeno que se quiere modelar.

6. Participación de los modelos

Las 57,406 batallas producen 114,812 apariciones de modelos, dos por enfrentamiento. La participación es desigual: los 10 modelos más frecuentes concentran 42.8% de las apariciones y la mitad superior de los modelos concentra 79.7%. gpt-4-1106-preview es el modelo con más apariciones (7,379), mientras mistral-7b-instruct-v0.2 registra 100, una razón aproximada de 74 a 1.

Modelo	Apariciones	% total	% como A
gpt-4-1106-preview	7,379	6.43%	49.7%
gpt-3.5-turbo-0613	7,075	6.16%	50.2%
gpt-4-0613	6,156	5.36%	50.3%
claude-2.1	5,580	4.86%	51.2%
claude-instant-1	4,124	3.59%	50.4%
gpt-4-0314	4,113	3.58%	50.6%
claude-1	3,971	3.46%	49.1%
vicuna-33b	3,716	3.24%	49.6%
mixtral-8x7b-instruct-v0.1	3,545	3.09%	49.1%
vicuna-13b	3,440	3.00%	49.4%

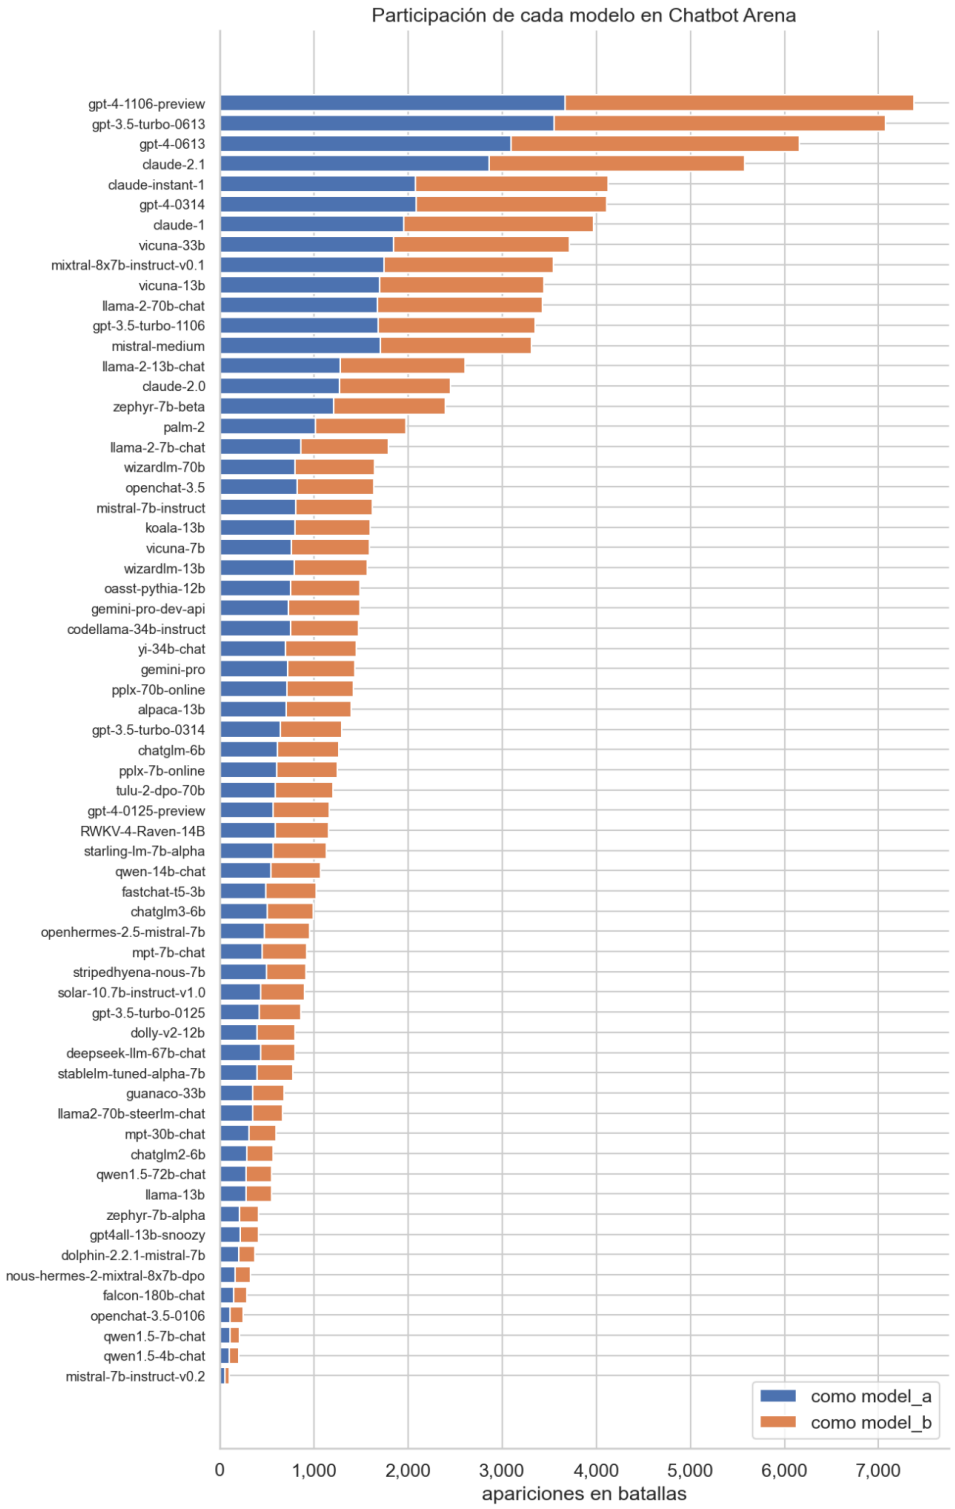


Figura 6. Participación de cada modelo en Chatbot Arena.

El reparto entre posiciones A y B es mucho más estable que la frecuencia de participación. En los 55 modelos con al menos 500 apariciones, la proporción en A se encuentra entre

47.7% y 54.1%. Esto es importante porque permite analizar el posible efecto de posición sin un desbalance grande de asignación por modelo.

7. Tasa de victoria por modelo

Para evitar rankings dominados por muestras pequeñas, el análisis principal de win rate se restringió a los 55 modelos con 500 o más apariciones. El win rate se definió como victorias dividido entre apariciones; los empates se reportan por separado.

Modelo	Apariciones	Win rate	Tie rate
gpt-4-1106-preview	7,379	55.14%	27.43%
gpt-3.5-turbo-0314	1,297	54.82%	25.37%
gpt-4-0125-preview	1,158	51.47%	31.09%
gpt-4-0314	4,113	48.46%	28.93%
claude-1	3,971	43.97%	29.72%
claude-instant-1	4,124	39.82%	29.17%
gpt-4-0613	6,156	39.73%	30.15%
qwen1.5-72b-chat	549	39.16%	32.79%
claude-2.0	2,451	39.00%	29.13%
llama-2-70b-chat	3,425	37.26%	32.47%

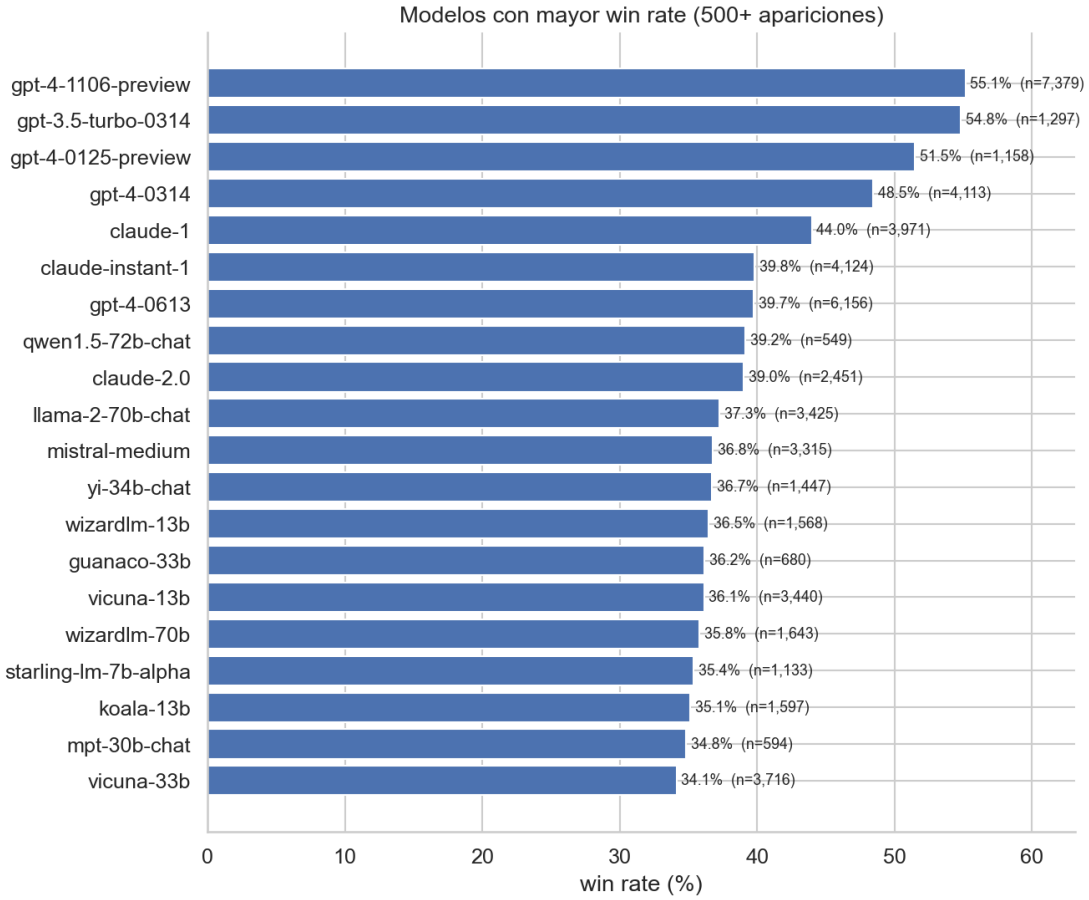


Figura 7. Modelos con mayor tasa de victoria entre los que tienen al menos 500 apariciones.

gpt-4-1106-preview presenta el mayor win rate observado: 55.14% en 7,379 apariciones. gpt-3.5-turbo-0314 queda muy cerca con 54.82%, pero sobre 1,297 apariciones. La diferencia de tamaño de muestra es relevante y evita interpretar el porcentaje como un ranking definitivo. Incluso los modelos superiores acumulan una cantidad considerable de derrotas y empates, por lo que el rendimiento depende también de los rivales enfrentados.

8. Win rate según posición A o B

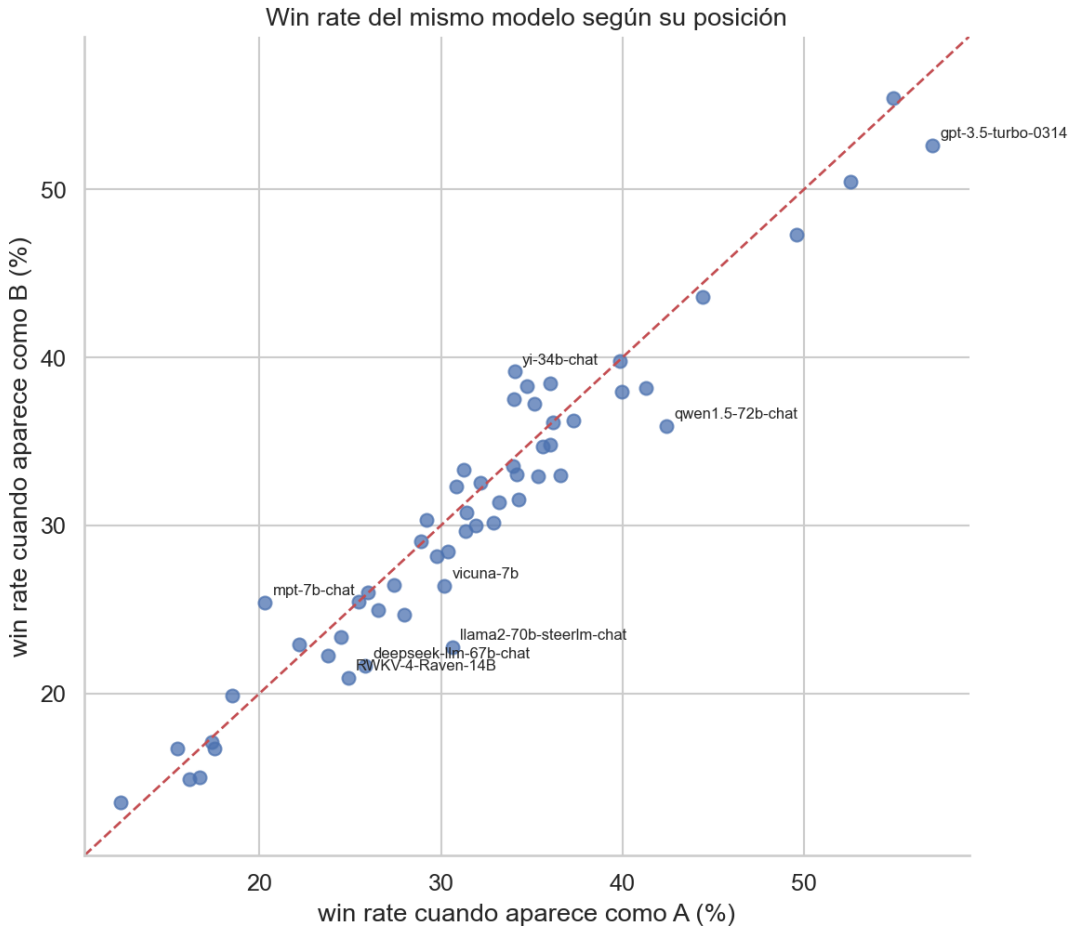


Figura 8. Tasa de victoria del mismo modelo según aparezca como A o como B.

La mayoría de los modelos se ubica cerca de la diagonal, señal de que su rendimiento es parecido en ambas posiciones. Las diferencias grandes no siguen una única dirección. llama2-70b-steerlm-chat registra 30.64% de victorias como A y 22.74% como B, una brecha de 7.89 puntos a favor de A. mpt-7b-chat, en cambio, obtiene 20.31% como A y 25.42% como B, 5.11 puntos a favor de B.

Estas diferencias individuales pueden estar relacionadas con la composición de rivales o con variación muestral. Por eso el posible sesgo de posición se evaluó también de forma agregada.

9. Empates por modelo y por enfrentamiento

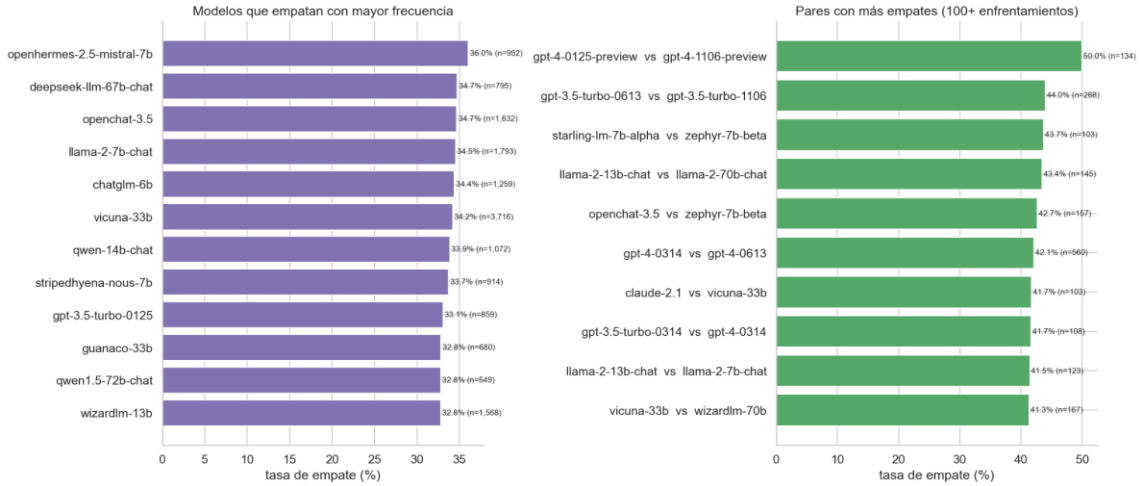


Figura 9. Modelos y pares de modelos con mayor tasa de empate.

Entre los modelos con al menos 500 apariciones, openhermes-2.5-mistral-7b registra la mayor tasa de empate: 36.03% en 952 batallas. Le siguen deepseek-llm-67b-chat (34.72% en 795) y openchat-3.5 (34.68% en 1,632). Estas cifras son superiores al empate global de 30.85%, pero la diferencia más clara aparece al revisar enfrentamientos concretos.

Entre pares con al menos 100 batallas, gpt-4-0125-preview contra gpt-4-1106-preview empata 50.00% de 134 veces. gpt-3.5-turbo-0613 contra gpt-3.5-turbo-1106 alcanza 44.03% en 268 casos y gpt-4-0314 contra gpt-4-0613 obtiene 42.14% en 560. Esto muestra que el empate no es una propiedad aislada de un modelo: depende de qué tan comparables sean los dos rivales presentados al evaluador.

10. Correlaciones

La etiqueta winner no se correlacionó directamente como 0, 1 y 2 porque esas cifras representan categorías nominales y no una escala ordenada. En su lugar se utilizaron los tres indicadores binarios originales. También se agregó dif_len, definida como longitud de A menos longitud de B.

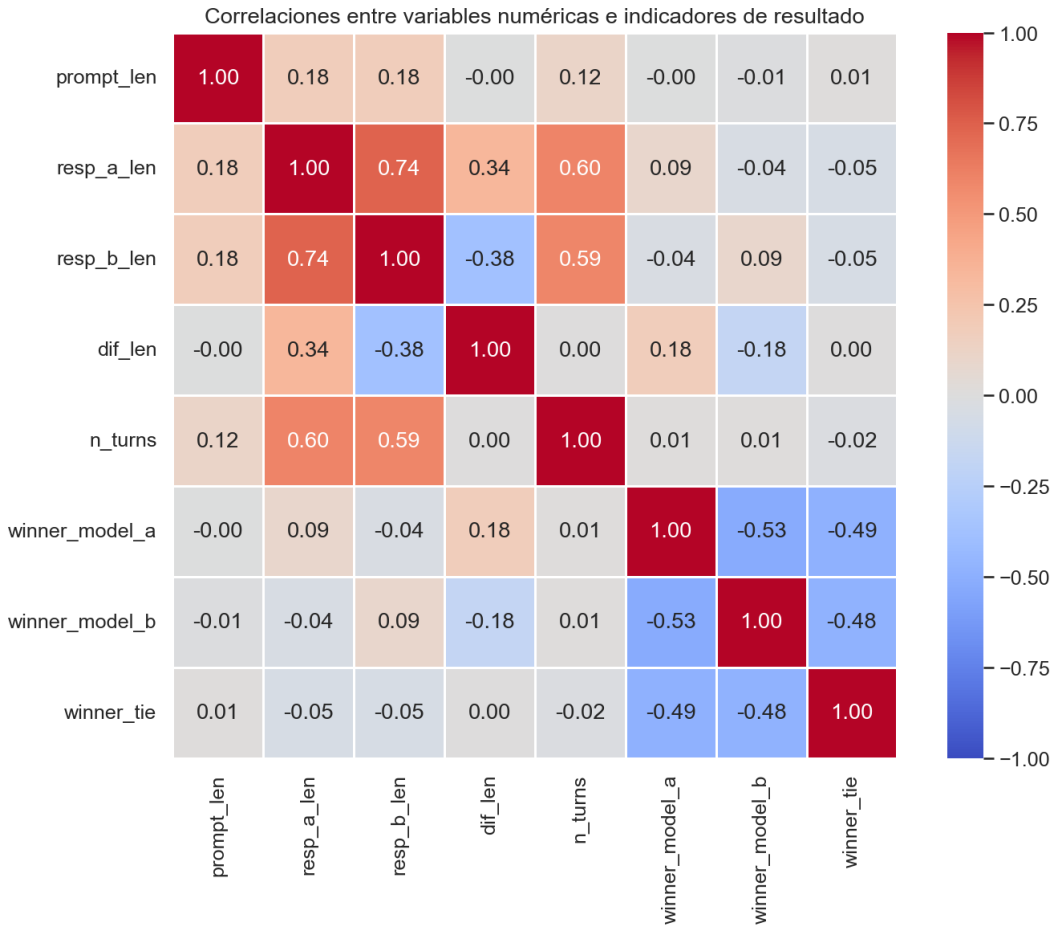


Figura 10. Correlaciones entre variables numéricas e indicadores de resultado.

La señal numérica más clara aparece en dif_len: correlación de +0.177 con victoria de A y -0.179 con victoria de B. La longitud de la respuesta A tiene correlación de 0.092 con victoria de A, y la longitud de B de 0.086 con victoria de B. La longitud del prompt y el número de turnos quedan cerca de cero.

Las correlaciones negativas entre winner_model_a, winner_model_b y winner_tie no deben interpretarse como causalidad porque los tres indicadores son mutuamente excluyentes. En conjunto, el heatmap confirma que no existe una variable numérica simple capaz de explicar la preferencia por sí sola.

11. Relación conjunta entre longitudes

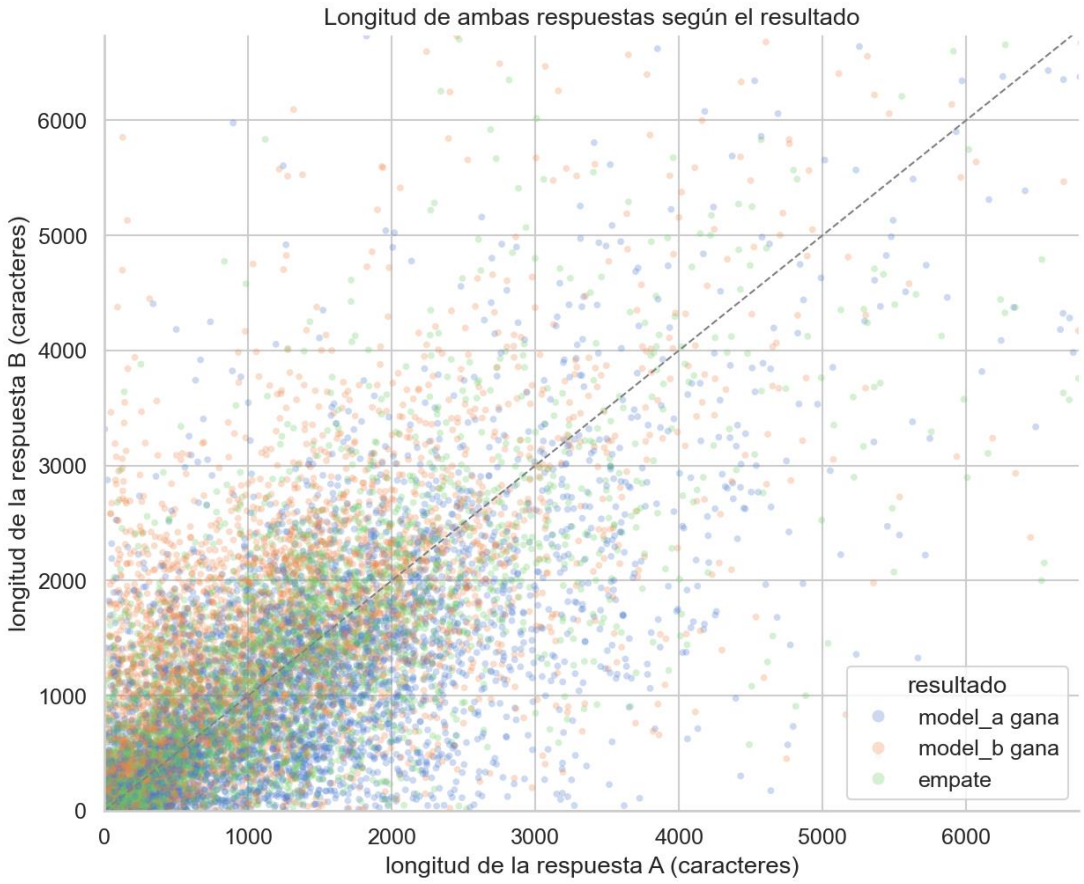


Figura 11. Longitud de la respuesta A frente a la respuesta B según el resultado.

El diagrama de dispersión muestra un alto solapamiento entre las tres clases. Las victorias de A se desplazan hacia zonas donde A es relativamente más extensa y las de B hacia el patrón inverso, pero no existe una frontera clara. Los empates se mezclan especialmente alrededor de la diagonal, donde ambas respuestas tienen extensiones parecidas. Esta visualización refuerza la conclusión de que la longitud aporta señal, pero no basta para reconstruir la decisión humana.

12. Evaluación global del posible sesgo de posición

En el dataset limpio A gana 20,055 batallas (34.94% del total), B gana 19,643 (34.22%) y se registran 17,708 empates (30.85%). Si se eliminan los empates solo para estudiar la posición entre batallas decisivas, A gana 50.52% y B 49.48%, una diferencia de 1.04 puntos porcentuales.

En paralelo, los modelos con 500 o más apariciones se asignan a A un promedio de 50.00% de las veces y su desviación absoluta media respecto a 50% es 1.02 puntos porcentuales. La ventaja global de A es pequeña y este EDA no permite afirmar que exista un sesgo causal o

estadísticamente demostrado. La posición sí debe conservarse como variable de control en el modelado posterior.

Conclusiones

Resumen de hallazgos

1. gpt-4-1106-preview presenta el desempeño observado más sólido entre modelos con muestra suficiente: 55.14% de victorias en 7,379 apariciones y 27.43% de empates. Su comportamiento también es estable entre posiciones A y B.
2. La longitud de la respuesta se relaciona con la preferencia. En batallas decisivas con longitudes distintas, la respuesta más larga gana 61.63% de las veces, pero el 38.37% restante muestra que verbosidad no equivale a calidad.
3. La diferencia de longitud es la característica numérica con mayor relación lineal con el resultado (+0.177 con victoria de A y -0.179 con victoria de B), mientras la longitud del prompt y el número de turnos tienen correlaciones casi nulas.
4. El empate es estructural: representa 30.85% de las batallas y su frecuencia cambia según el par de modelos. Algunos enfrentamientos comparables llegan a tasas de empate de 40% a 50%.
5. La participación de los modelos está fuertemente concentrada. Los 10 más frecuentes reúnen 42.8% de las apariciones y el modelo más observado tiene 74 veces más batallas que el menos observado. Las comparaciones deben acompañarse siempre por tamaño de muestra.
6. No se encontró evidencia descriptiva de un sesgo fuerte de posición. Entre batallas decisivas A supera a B por 1.04 puntos porcentuales y la asignación de los modelos a ambas posiciones se mantiene cercana a 50/50.
7. Los valores atípicos de longitud son, en su mayoría, conversaciones válidas de cola larga. Eliminarlos habría reducido información real; es preferible controlar su escala durante el modelado.

Conclusión

El análisis exploratorio permite concluir que la preferencia humana en Chatbot Arena no puede explicarse con una sola característica. La identidad del modelo, el rival, la extensión relativa de las respuestas y la existencia de empates aportan información, pero ninguna variable aislada domina el resultado. El comportamiento observado es consistente con un problema de preferencia por pares en el que la calidad percibida depende de la comparación entre dos respuestas, no de una puntuación absoluta de cada modelo.

La longitud es un factor de confusión importante. Los usuarios favorecen con mayor frecuencia la respuesta más larga, pero el efecto está lejos de ser perfecto. Cualquier ranking o modelo predictivo posterior debe separar la utilidad del contenido de la simple

verbosidad, porque de lo contrario podría aprender que escribir más es equivalente a responder mejor.

También debe controlarse la desigualdad de muestra entre modelos y la fuerza del rival. Un win rate bruto mezcla capacidad del modelo con el calendario de enfrentamientos que tuvo. Por esa razón, gpt-4-1106-preview puede considerarse el candidato observacional más fuerte dentro de este EDA, pero no se puede declarar como el mejor modelo para producción únicamente a partir de su porcentaje de victorias.

Desde una perspectiva de negocio, una selección de modelo debería combinar preferencia humana con costo, latencia, seguridad y comportamiento por tipo de tarea. El dataset analizado no contiene esas variables operativas, así que la recomendación final debe tratar el EDA como una primera capa de evidencia y no como una decisión completa de despliegue.

Siguientes pasos

- Construir un modelo multiclase que prediga victoria de A, victoria de B o empate, conservando el empate como clase explícita.
- Incorporar identidad de model_a y model_b, posición, número de turnos y variables de longitud transformadas.
- Agregar representaciones semánticas del prompt y de las respuestas para capturar calidad, contenido y estilo más allá de la longitud.
- Controlar la fuerza del rival con un enfoque de ranking por pares, por ejemplo un modelo tipo Bradley-Terry, o con variables que representen el historial de los modelos.
- Evaluar el modelo con particiones que reduzcan fuga de información entre prompts o enfrentamientos relacionados y comparar métricas por clase, no solo exactitud global.
- Para una decisión de producción, integrar métricas de costo, latencia, seguridad y desempeño por tipo de consulta junto con la preferencia observada.

Link del Repositorio

Repositorio

Referencias

Chiang, W.-L., Zheng, L., Sheng, Y., Angelopoulos, A. N., Li, T., Li, D., Zhang, H., Zhu, B., Jordan, M., Gonzalez, J. E., & Stoica, I. (2024). Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference. arXiv:2403.04132. https://arxiv.org/abs/2403.04132

Kaggle. (2024). LMSYS - Chatbot Arena Human Preference Predictions. https://www.kaggle.com/competitions/lmsys-chatbot-arena

Universidad del Valle de Guatemala. (2026). CC3084 - Data Science: Guía del Proyecto 2, Análisis Exploratorio. Departamento de Ciencias de la Computación.

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. arXiv:2306.05685. https://arxiv.org/abs/2306.05685