

Guía del Proyecto 2. Análisis Exploratorio

INTRODUCCIÓN

Dado que existen tantos problemas complejos que se pueden atacar con la Ciencia de Datos. Es por esto por lo que este año se plantean alternativas de proyecto. La actividad se realizará en grupos de 4 personas que deberán seleccionar uno de los siguientes retos de los que aquí se plantean:

#	Reto	Tema
1	Biohub - Cell Tracking During Development	Visión Artificial
2	Trace the Ace	Procesamiento del Lenguaje Natural
3	A Step Ahead of Drought: Forecasting Global. Water Storage Challenge by ITU	Series de tiempo con datos satelitales
4	Jigsaw - Agile Community Rules Classification	Procesamiento del Lenguaje Natural
5	MITSUI&CO. Commodity Prediction Challenge	Series de tiempo
6	MAP - Charting Student Math Misunderstandings	Procesamiento del Lenguaje Natural
7	RSNA Intracranial Aneurysm Detection	Visión Artificial
8	NeurIPS - Desafío de datos Ariel 2024	Visión Artificial
9	Clasificación degenerativa de la columna lumbar RSNA 2024	Visión Artificial
10	Predecir qué respuesta preferirá un usuario en esta batalla cara a cara con datos del Chatbot Arena	Procesamiento del Lenguaje Natural
11	Predicción de compradores recurrentes: cuestionar la línea base	Negocios
12	CommonLit - Evaluar resúmenes de estudiantes	Procesamiento del Lenguaje Natural
13	Detección de estructuras microvasculares en tejidos de riñón humano sanos.	Visión Artificial
14	Detectar y clasificar lesiones abdominales traumáticas	Visión Artificial
15	Google: reconocimiento de deletreo manual del lenguaje de señas estadounidense	Visión Artificial
16	Desafío Ojos en el Terreno del CGIAR. Detección de enfermedades en plantas	Visión Artificial
17	Identificación de Especies de Mosquitos	Visión Artificial
18	Hackeando el cuerpo humano	Visión Artificial
19	Predicción de argumentos efectivos	Procesamiento del Lenguaje Natural
20	Detección de fracturas de las vértebras cervicales en radiografías	Visión Artificial
21	Detección de pases en videos de jugadas de football de la liga alemana	Visión Artificial
22	Clasificación de los orígenes de un coágulo de sangre en un accidente cerebrovascular	Visión Artificial
23	Identificación de menciones de entidades biomédicas en resúmenes de artículos de investigación	Procesamiento del Lenguaje Natural

24	Identificación de relaciones de entidades biomédicas en resúmenes de artículos de investigación	Procesamiento del Lenguaje Natural
----	---	------------------------------------

Nota: Los primeros 3 retos son competencias activas.

INSTRUCCIONES

Sobre los Grupos:

- Deben inscribirse a alguno de los grupos de canvas para el proyecto 2. **Si no se inscribe en algún grupo no será calificado.**

Sobre los Retos:

- Cada grupo debe seleccionar un reto diferente, no pueden repetirse. Si esto sucediera se revisará la entrega del primer grupo que la realice.

Sobre el proyecto:

- Puede usar los recursos que kaggle o Google colab le proporciona, pero debe versionarlo en github puesto que sus contribuciones se usarán para la evaluación individual de cada miembro del grupo.

ACTIVIDADES

1. Haga una pequeña investigación del tema para que tenga idea de qué buscar en un análisis exploratorio. En el caso de los problemas médicos, describa la enfermedad a detectar, los síntomas y como se diagnostica (especialmente diagnóstico basado en imágenes). Esto le va a servir para entender cual es el patrón que deben reconocer los algoritmos. En el caso de problemas de Procesamiento del Lenguaje Natural, investigue las técnicas que se usan para detectar patrones en lenguaje escrito. En cuanto al tema de los negocios, investigue qué técnicas se usan para mejorar la retención de clientes y las ofertas.
2. Analice el problema planteado y los datos.
3. Describa las tareas de limpieza y preprocesamiento que llevó a cabo.
4. Haga un análisis exploratorio de los datos:
 - a. Comience describiendo cuantas variables y observaciones tiene disponible, el tipo de cada una de las variables.
 - b. Haga un resumen de las variables numéricas y tablas de frecuencia para las variables categóricas, escriba lo que vaya encontrando, si aplica.
 - c. Cruce las variables que considere que son las más importantes para hallar los elementos clave que lo pueden llevar a comprender lo que está causando el problema encontrado.
 - d. Haga gráficos exploratorios que le de ideas del estado de los datos.
5. Escriba unas conclusiones con los hallazgos encontrados durante el análisis exploratorio

EVALUACIÓN

NOTA: La evaluación de cada integrante del grupo será de acuerdo con sus contribuciones al trabajo grupal

- **(10 puntos) Situación Problemática:** Describe la situación problemática que da lugar al problema.
- **(10 puntos). Problema científico:** Se enuncia el problema científico que se desprende de la situación planteada. Se comprende bien cuál es el problema.
- **(10 puntos). Objetivos:** Se plantean los objetivos a cumplir para darle solución al problema planteado. Se enuncia al menos un objetivo general y 2 específicos. Los objetivos deben ser medibles y alcanzables durante la investigación.
- **(20 puntos). Descripción de los datos:** Se describen los datos, tanto las variables y observaciones como las operaciones de limpieza que se le hicieron si fueron necesarias.
- **(30 puntos). Análisis Exploratorio:**
 - o Estudia las variables cuantitativas mediante técnicas de estadística descriptiva.
 - o Hace gráficos exploratorios como histogramas, diagramas de cajas y bigotes, gráficos de dispersión que ayudan a explicar los datos.
 - o Analiza las correlaciones entre las variables, trata de explicar los outliers (puntos atípicos) y toma decisiones acertadas ante la presencia de valores faltantes.
 - o Estudia las variables categóricas
 - o Elabora gráficos de barra, tablas de frecuencia y de proporciones
 - o Explica muy bien todos los procedimientos y los hallazgos que va haciendo.
- **(20 puntos). Hallazgos y conclusiones:**
 - o Hace un resumen de los hallazgos en el análisis exploratorio
 - o Llega a conclusiones sobre los siguientes pasos a seguir.

MATERIAL A ENTREGAR

- Archivo .pdf con el informe de análisis exploratorio.
- Link del repositorio usado para versionar el código y/o link de kaggle o Google colab en caso de que los utilice.
- Presentación de Power Point a usar para presentar resultados.

FECHAS DE ENTREGA

- **PRESENTACIÓN Y DOCUMENTO FINAL COMPLETO: 11 de septiembre de 2025**

REFERENCIAS

- <https://www.kaggle.com/general/33266>
- <https://medium.com/analytics-vidhya/how-to-use-google-colab-with-github-via-google-drive-68efb23a42d>